Organización del Computador II

Segundo Cuatrimestre de 2009

Departamento de Computación
Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Trabajo Práctico 2

Procesamiento de imágenes para la detección de bordes en lenguaje ensamblador

Grupo XOR

Integrante	LU	Correo electrónico
Daniel Grosso	694/08	dgrosso@gmail.com
Nicolás Varaschin	187/08	nicovaras22@gmail.com
Mariano De Sousa	389/08	marian_sabianaa@hotmail.com

Índice

1. Introducción

En el presente trabajo, nos proponemos mejorar el programa de procesamiento de bordes realizado en el trabajo práctico anterior. La mejora sustancial consiste en utilizar el modelo de instrucciones SIMD con instrucciones SSE y diversas optimizaciones en el algoritmo para lograr un mejor rendimiento del programa.

A los algoritmos de Roberts, Prewitt y Sobel, que ya implementamos en el trabajo anterior, se le sumara el algoritmo de Frei-Chen. Para ello, asumiendo un ancho de imagen múltiplo de 16 píxeles, se procesaran en paralelo 14 píxeles en cada ciclo del programa logrando una considerable mejora en la performance.

El trabajo está orientado fuertemente a lograr velocidad, sacrificando necesariamente legibilidad del código, modularización y simpleza para cumplir el objetivo. Luego el resultado será comparado con previas implementaciones para mostrar las diferencias de rendimiento de cada uno.

La interfaz con el usuario, escrita en lenguaje C, será similar a la del trabajo anterior y se detallará la nueva implementación en ensamblador en las siguientes secciones.

2. Desarrollo

El desarrollo de este trabajo se basó en modificar la implementación anterior con el fin de alcanzar los objetivos. Para lograr una mejor performance usando instrucciones del set SSE se propusieron diversos algoritmos posibles, siendo el último de los que describimos a continuación el elegido para la versión final. En todo momento se asumió un ancho de imagen múltiplo de 16 píxeles y cada algoritmo fue pensado independientemente de la matríz a usar.

El primer algoritmo pensado agarraba 16 píxeles, los 16 píxeles por encima y los 16 píxeles por debajo de esos de la siguiente manera:

```
xmm0  x  x  x  x  x  x  x  x  x  x  x  x  x  x  x  x
xmm1  x  p  p  p  p  p  p  p  p  p  p  p  p  p  p  x
xmm2  x  x  x  x  x  x  x  x  x  x  x  x  x  x  x  x
```

Sólo los píxeles indicados con una `p` se procesaban, usando como información adicional los que están marcados con una `x`.

Luego la matríz correspondiente se cargaba varias veces en otros registros `xmm`, de tal forma que pudieran ser procesados los 14 píxeles buscados en un solo ciclo del bucle principal. Luego, como la imagen es múltiplo de 16 píxeles, se avanzaba esa cantidad para seguir procesando. Esto creó un problema insalvable en el algoritmo: el último píxel de un ciclo y el primero del siguiente ciclo no se procesaban. Se pensó en salvar este problema manipulando esos dos píxeles con registros generales, pero la complejidad del algoritmo aumentaría y se optó por pensar un método más eficaz.

Un segundo algoritmo se basaba en cargar 16 píxeles a procesar, siendo 8 pertenecientes a una fila y los 8 restantes a la fila siguiente, cargando a su vez toda la información necesaria para procesar los dos conjuntos de 8 píxeles. La ventaja de este método está en la simplificación de cálculos, ya que al tratarse de *bytes* sin signo que tienen que ser multiplicados por algún posible valor signado en la matríz del operador, se tiene que extender el *byte* a *word*. Entonces entrando 8 *words* en cada registro `xmm`, tiene sentido procesar de a 8 píxeles. El problema de este método era la ineficiencia en accesos a memoria, y que al tener que procesar de a dos filas al mismo tiempo, el alto de la imagen tenia que ser múltiplo de dos, o manejar el caso impar de otra forma, y esto no era conveniente.

El tercer algoritmo volvió a la idea del primero, procesar de a 14 píxeles. La diferencia está en que procesaba 14 píxeles del principio de la fila y a la vez, 14 del final de la fila y en vez de avanzar de a 16 píxeles, avanzaba de a 14 tanto desde el comienzo hacia el final de la fila como del final hacia el comienzo y cuando llegaba a la mitad de la fila, pasaba a la siguiente. La principal ventaja es que nos librábamos del problema de saber cuando terminó una fila, ya que, recorriendo de ambos lados a la vez, a lo sumo se procesarían dos veces algunos píxeles del medio. El problema fue que este algoritmo necesitaba una mayor cantidad de registros e implicaba un difícil manejo de punteros.

El algoritmo final es una modificación del anterior: se procesan 14 píxeles y

se avanza de a 14 píxeles de izquierda a derecha solamente, y cuando el ancho restante de la imagen es menor que 14 píxeles, se procesan 14 de derecha a izquierda. Otra vez, a lo sumo se procesarán dos veces algunos píxeles del final, pero se justifica, ya que cuesta mas ciclos revisar el ancho y procesar esos píxeles restantes de alguna otra forma.

En la siguiente sección se detalla el funcionamiento del algoritmo junto con diferentes problemas que surgieron al programarlo.

3. Discusión

El código de este trabajo utiliza las funciones en lenguaje `C` del trabajo anterior y nuevas funciones en assembler. El trabajo en assembler está separado en un archivo por filtro a aplicar y un archivo para las *macros* en común, utilizadas por los filtros.

A continuación se detallara lo escrito y pensado para los diferentes algoritmos, que fueron ajustados para mejor rendimiento según la matríz utilizada. Antes de empezar se definen nombres específicos (*macros*) para cada registro `xmm`, para facilitar la lectura del código. Los nombres definidos son: `srcl`, `srch` que contendrán las líneas leídas de la imagen original; `acul`, `acuh` que acumularán los resultados parciales del cálculo; y cuatro registros temporales `tmp1`, `tmp2`, `tmp3` y `tmp4` (en el caso del *Frei-Chen* el cuarto registro temporal se renombra a `sqrt2`).

Los algoritmos siguen una línea general, empiezan y terminan con lo definido en la convención C, se definen nombres de variables para los parámetros y se usan los registros generales de la siguiente manera:

- `eax`: Almacena las variables `xOrder` e `yOrder` que indican sobre qué derivada realizar el procesamiento.
- `ebx`: Contador para las filas.
- `ecx`: Contador para las columnas.
- `edx`: Ancho de la imagen.
- `esi`: Puntero a la imagen fuente.
- `edi`: Puntero a la imagen destino.

Luego para cada fila de la imagen se realiza el procesamiento sobre la derivada de `x` o de `y` según sea necesario procesando de a 14 píxeles, y antes de terminar la fila se revisa si se pueden calcular exactamente 14 píxeles, sino se retroceden los punteros para poder lograrlo y se pasa a la siguiente fila.

3.1. Estructura básica para *Sobel*, *Prewitt* y *Frei-Chen*

Los algoritmos de *Sobel*, *Prewitt* y *Frei-Chen* están estructurados de la misma manera. Cada uno tiene definidas sus propias *macros* denominadas `procesarLineaX`, `procesarLineaY`, `calcularX` y `calcularY`. De esta manera, el código de los tres filtros es bastante similar y para comprenderlos basta con entender la estructura básica de uno de ellos y luego los detalles particulares. La idea general del procesamiento se basa en las *macros* `procesarLineaX/Y`. Cada *macro* se encarga de leer 16 píxeles, desempaquetarlos, hacer el procesamiento de los 14 píxeles procesables según la línea correspondiente de la matríz, y sumar el resultado de la operación en dos acumuladores. Las macros `calcularX` y `calcularY` son las encargadas de efectuar el procesamiento en paralelo de 6 píxeles convertidos a *word*. Cada algoritmo tiene sus versiones de ambas *macros*. Como estas *macros* no procesan todos los píxeles necesarios por limitaciones del método, cada algoritmo calcula individualmente los 2 píxeles centrales de los 16 levantados. Por último, se empaquetan los datos a *bytes*, se guardan en la imagen resultante y

se avanza en la imagen hasta completar el procesamiento. A continuación serán explicados los diferentes algoritmos de paralelización utilizados en cada caso.

3.2. Sobel

3.2.1. Procesamiento en `x`

La *macro* `procesarLineaX` comienza cargando en los registros `srcl` y `srch` 16 píxeles de la imagen original, luego desempaqueta a ocho *words* adecuadamente con las instrucciones `punpcklbw` (*Unpack Low Bytes to Words*) y `punpckhbw` (*Unpack High Bytes to Words*). Mediante la *macro* `calcularX` se trabajan ocho píxeles, que serán primero los menos significativos (contienidos en el registro `srcl`) y después los más significativos (contenidos en el registro `srch`). Al aplicar convolución entre la primer línea de la matríz de *Sobel* (| -1 | 0 | 1 |) y una línea genérica | a | b | c | ... | , el resultado esperado es | c-a | d-b | e-c | . La *macro* `calcularX` obtiene el resultado esperado de 6 píxeles en paralelo para *Sobel* en `x` de la siguiente manera:

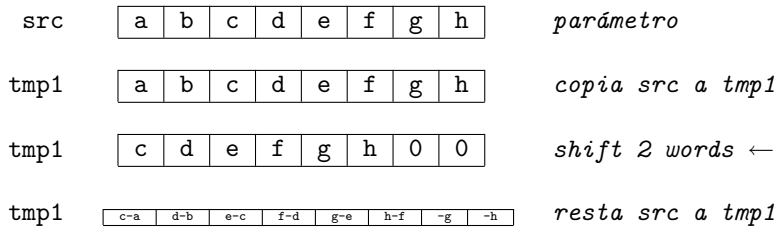

Luego de obtener el resultado mostrado en el esquema, se suman los 6 resultados válidos al acumulador correspondiente. Como la primer y tercer líneas de la matríz de *Sobel* son iguales y la segunda es el doble de la primera, se procesan todas las líneas con la misma *macro*. En el caso de estar procesando la segunda línea de la matríz (| -2 | 0 | 2 |), después de ejecutar la *macro* `calcularX`, se duplica el resultado obtenido.

Los valores intermedios se acumulan en `acul` y `acuh`. Una vez calculados, se procesan individualmente y aprovechando los resultados intermedios obtenidos, los dos píxeles centrales de los 14 píxeles originales que debían ser procesados ya que este método impide procesarlos en paralelo.

3.2.2. Procesamiento en `y`

La idea detrás del procesamiento de Sobel en `y` es básicamente la misma al procesamiento en `x`. En este caso, al aplicar convolución entre la primer línea de la matríz (| -1 | -2 | -1 |) y una línea genérica (| a | b | c | ... |), el resultado esperado es | -a-2b-c | -b-2c-d | -c-2d-e | . Para obtener este resultado, se realiza el siguiente procedimiento:

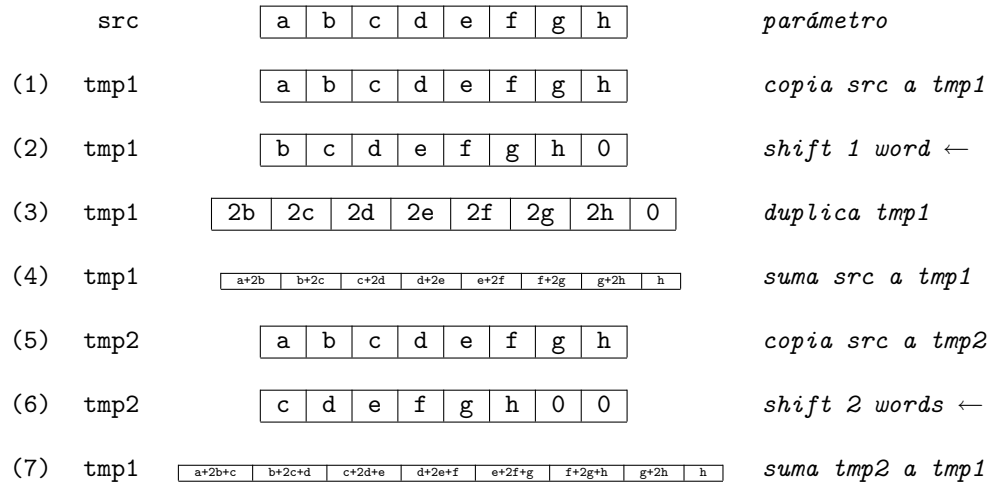

Luego de obtener el resultado mostrado en el esquema, se acumula el resultado de `calcularY` restando (en caso de estar calculando la primer línea de la matríz) o sumando (si se trata de la tercera). Esto se debe a que la matríz es igual en ambas líneas, salvo porque la primer línea es negativa. Como la matríz contiene sólo ceros en la segunda línea, no es necesario realizar los cálculos.

Al igual que para *Sobel* en `x`, después de calcular los resultados intermedios, se procesan individualmente los 2 píxeles faltantes.

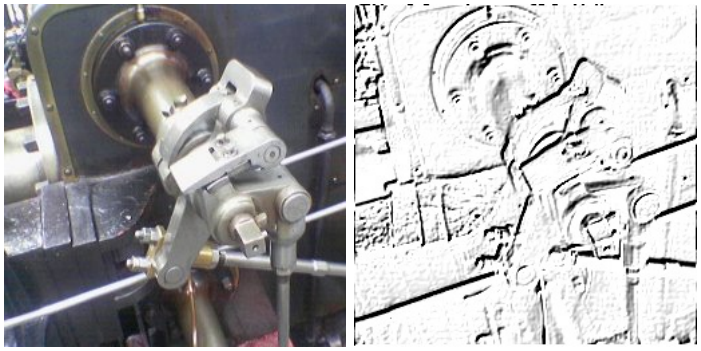

Ejemplo del filtro Sobel negado

3.3. Prewitt

Este algoritmo es casi idéntico al anterior. El único cambio general es que, luego de procesar las líneas pero antes de empaquetar a *bytes*, se calcula el valor absoluto de los acumuladores.

3.3.1. Procesamiento en `x`

El cálculo de *Prewitt* en `x` es idéntico al de la primer línea de *Sobel*. Basta con no cambiar de línea y realizar los mismos pasos para obtener el resultado correcto.

3.3.2. Procesamiento en y

El cálculo de *Prewitt* en `y` es similar al de *Sobel*. El único cambio en el algoritmo es que no se efectúa el paso (3). es decir, no se duplica el valor de la segunda columna de `src` sino que se suma directamente.

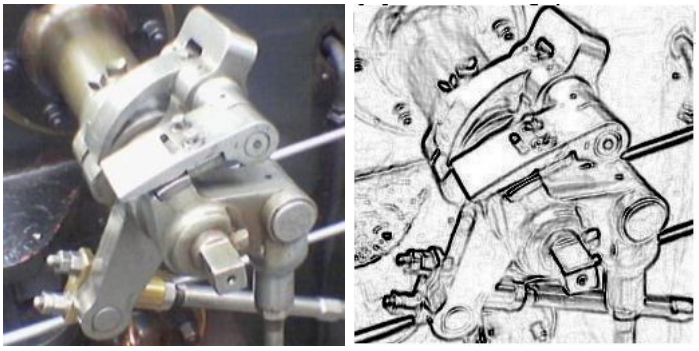

`Ejemplo del filtro Prewitt negado`

3.4. Frei-Chen

La matríz de *Frei-Chen* contiene números reales además de números enteros. Para hacer de forma más eficiente el algoritmo, primero se precalcula $\sqrt{2}$ en un registro temporal (`sqrt2`) mediante la instrucción `sqrtps` (*Square Root Parallel Single*) ya que es el único número real presente en la matríz.

`sqrt2`	$\sqrt{2}$	$\sqrt{2}$	$\sqrt{2}$	$\sqrt{2}$	*raíces de 2*

Al tener que multiplicar por un número real, los cálculos intermedios son convertidos a *float*. Por limitaciones del set de instrucciones `IA-32`, a la hora de realizar la conversión, se extienden los enteros de 16 *bits* a 32 *bits*. Para realizar la extensión signada, se utilizó la instrucción `pcmpgtw` junto con `punpckhwd` y `punpcklwd` comparando el registro a extender con un registro en 0 como se muestra en el siguiente ejemplo:

`tmp3`	0	0	0	0	0	0	0	0	*tmp3 = 0*
`tmp1`	-5	123	-145	100	66	-93	80	3	*tmp1 en words*
`tmp2`	-5	123	-145	100	66	-93	80	3	*tmp2 = tmp1*
`tmp3`	0xFFFF	0	0xFFFF	0	0	0xFFFF	0	0	`pcmpgtw` *tmp2, tmp3*
`tmp1`	-5	123	-145	100					`punpcklwd` *tmp1, tmp3*
`tmp2`	66	-93	80	3					`punpckhwd` *tmp2, tmp3*

Al igual que en *Prewitt*, luego de procesar las líneas pero antes de empaquetar a *bytes*, se calcula el valor absoluto de los acumuladores.

3.4.1. Procesamiento en `x`

El algoritmo realizado para *Frei-Chen* en `x` es similar al de *Sobel*. En este caso, la diferencia reside únicamente en el cálculo de la segunda línea de la matríz ($\boxed{-\sqrt{2} \mid 0 \mid \sqrt{2}}$). Para calcular esta línea, se aprovecha la propiedad distributiva de la multiplicación respecto de la suma y la resta, calculando primero la resta en enteros, luego convirtiendo a *float* y multiplicando el resultado por $\sqrt{2}$. Una vez hechas las operaciones, se convierte el resultado de *float* a *dword*, para finalmente convertirlo a *word*.

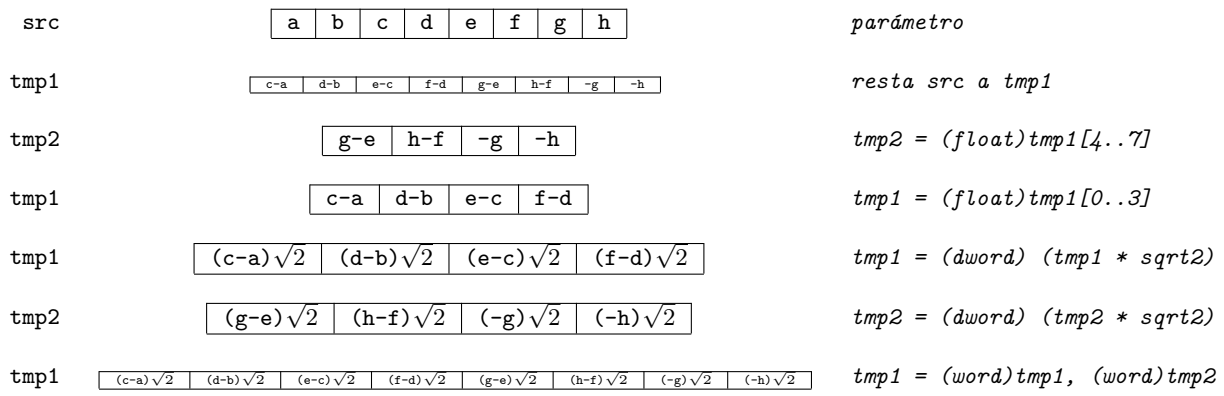

Luego el algoritmo continúa igual que el algoritmo de *Sobel*, salvando los cálculos individuales de los píxeles centrales que vuelve a realizar un procedimiento similar al ya mostrado.

3.4.2. Procesamiento en `y`

Siguiendo la idea de la implementación de *Sobel*, el algoritmo para *Frei-Chen* en `y`, se diferencia en la segunda columna de la matríz, que está multiplicada por $\sqrt{2}$ en lugar de por 2. La única diferencia con *Sobel* se va a encontrar en que se necesita realizar la multiplicación en punto flotante en cada llamada a la macro `calcularY`. Es decir, se reemplaza el paso (3) del algoritmo de *Sobel* por la conversión a punto flotante y la multiplicación por $\sqrt{2}$. La forma de multiplicar es igual a la utilizada para *Frei-Chen* en `x` y descripta anteriormente.

Ejemplo del filtro Frei-Chen negado

3.5. Roberts

La implementación del operador de *Roberts*, se basa en la explicada anteriormente para *Sobel*, pero es más simple y concisa, ya que la matríz es de 2x2. La principal ventaja de este tamaño de matríz es que permite calcular de a 15 píxeles. Al igual que en el algoritmo de *Prewitt* y *Frei-Chen*, luego de procesar las líneas pero antes de empaquetar a *bytes*, se calcula el valor absoluto de los acumuladores.

3.5.1. Procesamiento en `x`

La macro `RobertsX` obtiene 16 píxeles, los desempaqueta a *words* y los suma a los acumuladores directamente, ya que la primer línea de la matríz de *Roberts* es | 1 | 0 | . Luego avanza una linea, desempaqueta los 16 nuevos píxeles, *shiftea* una *word* a la derecha y se restan a los ya acumulados, logrando así el procesamiento de la segunda línea de la matríz buscada(| 0 | -1 |). El siguiente esquema muestra el procesamiento de un fragmento de Roberts suponiendo el acumulador vacío al iniciar:

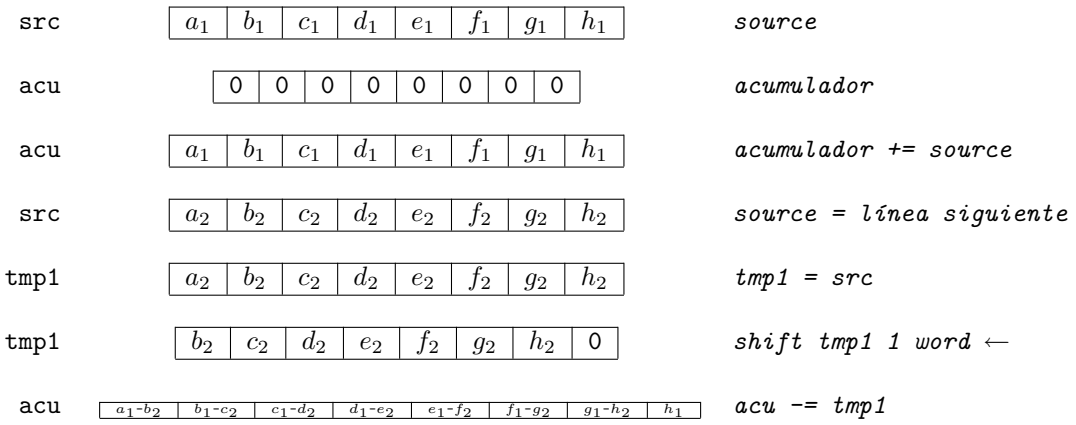

3.5.2. Procesamiento en `y`

La macro `RobertsY` funciona de igual manera, sólo que se invierte el órden del procesamiento, es decir, el cálculo que se hacía en `RobertsX` para la primer línea, ahora se hace para la segunda y viceversa. Jústamente, esto se debe a que la matríz de *Roberts* en `y` es exactamente espejada en filas que la matríz de *Roberts* en `x`.

`Ejemplo del filtro Roberts negado`

3.6. Medición de Performance

La siguiente tabla muestra la cantidad de ciclos mínima y promedio de cada implementación de los filtros, obtenidos de una muestra de 1000 ejecuciones de cada uno sobre la imagen de prueba `lena.bmp`:

Implementación	Ciclos de reloj	
	Mínimo	Promedio
Sobel		
Assembler	58.720.540	60.010.675
C	393.586.848	416.838.429
OpenCv	9.338.589	9.797.886
SSE	2.055.594	2.078.737
Roberts		
Assembler	34.714.238	42.746.947
C	320.676.453	336.808.912
SSE	863.490	879.187
Prewitt		
Assembler	60.428.397	63.629.648
C	634.337.521	664.132.063
SSE	2.077.712	2.090.116
Frei-Chen		
SSE	4.005.108	4.038.886

El rendimiento logrado con SSE es notable, las nuevas implementaciones son aproximadamente 30 veces más rápidas que las implementaciones sin SSE y en el caso de *Sobel*, es alrededor de 4 veces más rápida que la implementación original de la librería. Esto demuestra definitivamente el poder de trabajo de SSE para aplicaciones multimedia.

4. Conclusiones

Con respecto al trabajo actual, se presentó un método efectivo aun más eficiente que el expuesto en el trabajo anterior, ya que el trabajo mediante SSE permitió procesar gran cantidad de datos en paralelo, crucial para este tipo de aplicaciones.

Es notable la diferencia entre las diferentes implementaciones surgida al comparar los tiempos. Ya en previo trabajo puede verse que la implmentación en lenguaje C es la más lenta de todas, seguida de la implementación en ensamblador y, siendo mucho mas rápida, está la implementación de la librería openCv. Pero este nuevo algoritmo es varias veces más rápido que el de la librería, demostrando que el trabajo de hacer un algoritmo más complejo que usa instrucciones SIMD para lograr mejoras en la performance, está perfectamente justificado.

Para concluir, con el presente trabajo se muestra una herramienta de muy alto rendimiento de realce de bordes en imágenes, la cual puede ser útil a gran escala por sus prestaciones o bien formar parte de otro tipo de proyecto, por ejemplo, realce de bordes en video en tiempo real.

5. Manual de usuario

5.1. Ayuda rápida

Uso:
`./bordes [opciones] [archivo]`

Opciones:

```
 -r#        Aplica el operador #
 -g         Modo gráfico
 --nosse    Deshabilita las optimizaciones de SSE
 --time #   Realiza # repeticiones del operador y muestra información de performance
```

Operadores posibles:

1: Operador de Roberts
2: Operador de Prewitt
3: Operador de Sobel derivando por X
4: Operador de Sobel derivando por Y
5: Operador de Sobel derivando por X e Y
6: Operador de Frei-Chen

Si no se especifica un archivo de entrada, se usará `lena.bmp`

5.2. Descripción

El programa se puede invocar en modo gráfico (`-g`) o directo (`-r#`) y opcionalmente una imagen. En modo directo, se leerá una imagen pasada como parámetro o la imagen por defecto (`lena.bmp`), se le aplicará el filtro seleccionado y se guardará con el nombre original mas un postfijo que indica que filtro fue aplicado y con la extensión original. En modo gráfico, se puede abrir una imagen y aplicar los filtros, con las teclas del `1` al `6`, restaurar la imagen en escala de grises con la tecla `0`, guardar el resultado actual con la tecla `s` y deshabilitar las optimizaciones con la tecla `o`. Se puede salir de este modo con la tecla `ESCAPE`.

Tipos de imágenes soportados:

- `Windows bitmaps - BMP, DIB`
- `JPEG files - JPEG, JPG, JPE`
- `Portable Network Graphics - PNG`
- `Portable image format - PBM, PGM, PPM`
- `Sun rasters - SR, RAS`
- `TIFF files - TIFF, TIF`

(extraído de la documentación de la librería *OpenCv*)

5.3. Instrucciones de compilación

Dirigirse a la carpeta del código (`src/`) y ejecutar el comando `make`.